

# Chapitre 9

## Statistiques et simulation

### I. Le problème

On réalise  $n$  fois une expérience aléatoire qui conduit à une distribution de fréquences observées et on souhaite évaluer l'**adéquation** de ces données **expérimentales** à une **loi équirépartie**.

<i>Distribution des fréquences observées</i>							<i>Loi équirépartie</i>						
valeur	$x_1$	$x_2$	...	$x_i$	...	$x_n$	issue	$x_1$	$x_2$	...	$x_i$	...	$x_n$
fréquence	$f_1$	$f_2$	...	$f_i$	...	$f_n$	probabilité	$\frac{1}{k}$	$\frac{1}{k}$	...	$\frac{1}{k}$	...	$\frac{1}{k}$

#### Exemple :

Un pisciculteur possède un bassin qui contient 3 variétés de truites : communes, saumonées et arc-en-ciel. Il voudrait savoir s'il peut considérer que son bassin contient autant de truites de chaque variété.

### II. Les étapes du test

#### 1) Prélèvements réels

#### Exemple :

Il effectue, au hasard, 400 prélèvements d'une truite avec remise.

Il obtient ainsi : 146 truites communes, 118 truites saumonées et 136 truites arc-en-ciel.

Notons  $f_c$ ,  $f_s$  et  $f_a$  les fréquences correspondantes.

On a donc :

$$f_c = \frac{146}{400} = 0,365$$

$$f_s = \frac{118}{400} = 0,295$$

$$f_a = \frac{136}{400} = 0,340$$

## 2) Calcul de $d_{obs}^2$

On mesure la « distance » entre la distribution des fréquences et la loi équirépartie.

On calcule :

$$d_{obs}^2 = \sum_{i=1}^k \left( f_i - \frac{1}{k} \right)^2$$

### Remarque :

On rejettera l'hypothèse d'équirépartition si l'éloignement  $d_{obs}^2$  est assez flagrant : on va déterminer un seuil au-delà duquel il en est ainsi.

### Exemple :

$$d_{obs}^2 = \left( f_c - \frac{1}{3} \right)^2 + \left( f_s - \frac{1}{3} \right)^2 + \left( f_a - \frac{1}{3} \right)^2 = \left( 0,365 - \frac{1}{3} \right)^2 + \left( 0,295 - \frac{1}{3} \right)^2 + \left( 0,340 - \frac{1}{3} \right)^2 \approx 0,00252$$

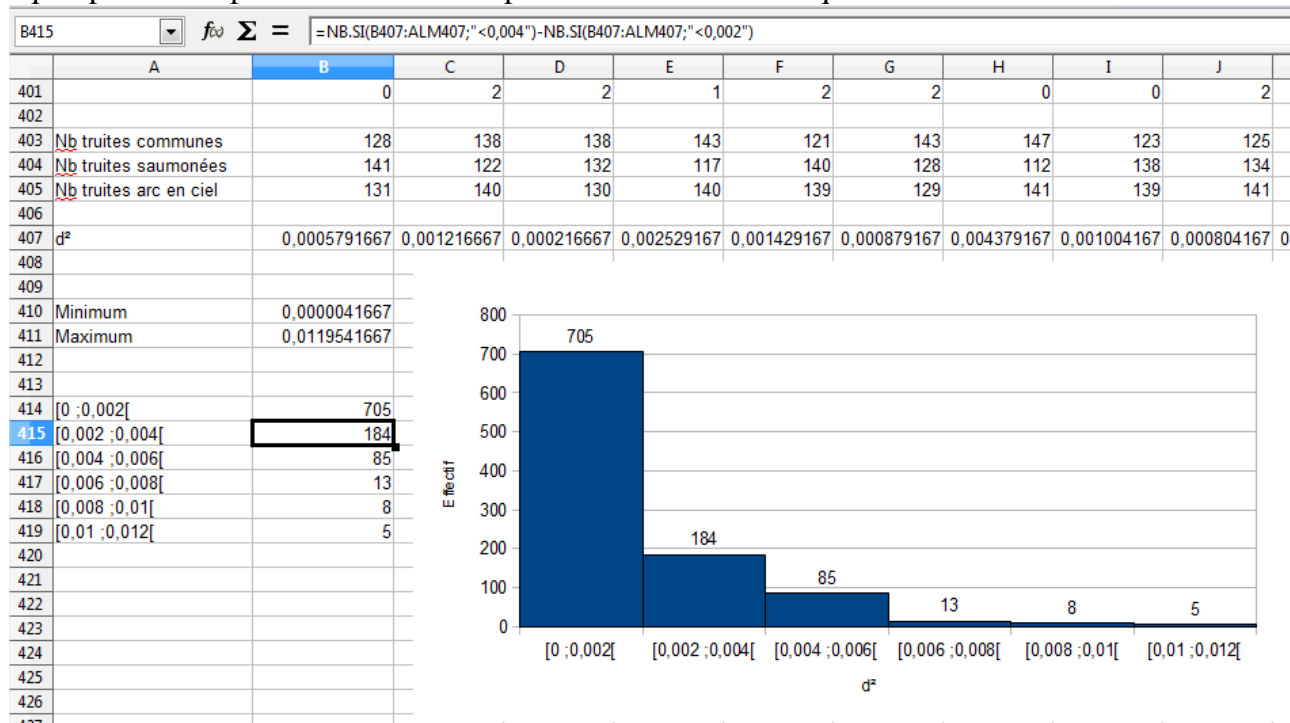
## 3) Simulation

On réalise une simulation de  $N$  échantillons de taille  $n$  de la loi équirépartie à  $k$  issue.

Pour chaque échantillon, on calcule la distance  $d^2$  ; on obtient une série de  $N$  valeurs  $d_1, d_2, \dots, d_N$ .

### Exemple :

A l'aide d'un ordinateur, le pisciculteur simule le prélèvement au hasard de 400 truites suivant la loi équirépartie. Il répète 1000 fois cette opération et calcule à chaque fois la valeur  $d^2$ .



Parmi les 1000 prélèvements de 400 truites, 705 prélèvements ont un  $d^2$  compris entre 0 et 0,002 ; 184 prélèvements ont un  $d^2$  compris entre 0,002 et 0,004.

**Définition :**

Le **neuvième décile** (empirique) est le plus petit élément  $D_9$  des valeurs des termes de la série, tel qu'au moins 90 % des données soient inférieures ou égales à  $D_9$ .

On s'intéresse, en fait, au 9<sup>e</sup> décile  $D_9$  de la série :

B423		$f_{\infty} \Sigma =$	=CENTILE(B407:ALM407;0,9)	
	A	B	C	
401		0	2	
402				
403	Nb truites communes	128	138	
404	Nb truites saumonées	141	122	
405	Nb truites arc en ciel	131	140	
406				
407	$d^2$	0,0005791667	0,001216667	0,00
408				
409				
410				
411				
412				
413				
414	Minimum	0,0000041667		
415	1 <sup>er</sup> décile	0,0002041667		
416	2 <sup>e</sup> décile	0,0003791667		
417	3 <sup>e</sup> décile	0,0005541667		
418	4 <sup>e</sup> décile	0,0008291667		
419	5 <sup>e</sup> décile	0,0011416667		
420	6 <sup>e</sup> décile	0,0015041667		
421	7 <sup>e</sup> décile	0,0019616667		
422	8 <sup>e</sup> décile	0,0026791667		
423	9 <sup>e</sup> décile	0,0041166667		
424	Maximum	0,0119541667		
425				

Sur l'exemple, on constate que 90% des valeurs de la série des  $d^2$  sont inférieures à ~0,004117.

#### 4) Règle de décision

On compare  $d_{obs}^2$  et  $D_9$ .

- Si  $d_{obs}^2 > D_9$ , **on peut**, avec un risque d'erreur inférieur à 10%, rejeter l'adéquation des données observées à une loi équirépartie.
- Si  $d_{obs}^2 \leq D_9$ , **on ne peut pas**, avec un risque d'erreur inférieur à 10%, rejeter l'adéquation des données observées à une loi équirépartie.

**Exemple :**

On constate que  $d_{obs}^2 = 0,00252 < D_9 = 0,00411$ .

On dit alors, avec un risque d'erreur inférieur à 10% que « le bassin contient autant de truite de chaque variété ».

**Remarques :**

- Parfois, on introduit un coefficient multiplicateur pour  $d_{obs}^2$ . C'est en particulier le cas lorsque la taille  $n$  de l'échantillon observé et la taille  $n'$  des  $N$  simulations ne sont pas les mêmes.

On compare alors  $nd_{obs}^2$  au 9<sup>e</sup> décile  $D'_9$  de la série des  $N$  valeurs  $n'd^2$ .

- Si au lieu du 9<sup>e</sup> décile, on utilise par exemple le 95<sup>e</sup> centile, la règle de décision sera :  
Si  $d_{obs}^2 > C_{95}$ , on peut avec un risque d'erreur inférieur à 5%, rejeter l'adéquation des données à une loi équirépartie.